

RAPPORT DE PROJET DE FIN D'ÉTUDES

Predicting Tox21 Toxicity via Consensus Machine Learning Enhanced by Data-Driven Threshold Optimization

Bioinformatique computationnelle | Machine Learning | Toxicologie prédictive | Déploiement web

Réalisé par

Mohamed BEN DIFI

Master IA

Ayman CHABBAKI

Master IA

Encadrement

Encadrant

Pr. Benlahmar El Habib

Co-encadrante

Mme. Hannouni Salma

Année universitaire 2025 – 2027

Résumé

La prédiction de la toxicité in vivo à partir de données de criblage à haut débit (qHTS) in vitro demeure un verrou critique en toxicologie computationnelle. Le jeu de données Tox21 présente des défis significatifs liés au déséquilibre de classes extrême et au bruit de haute dimension dans l'espace des descripteurs moléculaires. Ce rapport présente un pipeline consensus de machine learning optimisé pour prédire la toxicité sur 12 endpoints biologiques distincts couvrant les voies des récepteurs nucléaires et des réponses au stress cellulaire.

L'approche repose sur des empreintes moléculaires ECFP4 générées avec RDKit (rayon 2, 1024 bits), une sélection de caractéristiques à deux étapes endpoint-spécifique réduisant la dimensionnalité d'environ 79%, et un modèle consensus combinant Bernoulli Naïve Bayes et XGBoost pondéré par les scores ROC-AUC. La contribution principale est l'abandon des seuils de classification fixes (0.50) au profit de seuils dynamiques optimisés par le Coefficient de Corrélation de Matthews (MCC). Cette méthode a permis d'atteindre une AUC-ROC de 0.8835 sur NR-AhR et d'identifier avec précision le Bisphénol A (NR-ER : 0.964) et le Benzo[a]pyrène (NR-AhR : 0.994) via leurs voies mécanistiques exactes.

Mots-clés : Toxicologie prédictive, Tox21, Machine Learning, XGBoost, Modèle consensus, Déséquilibre de classes, Optimisation MCC, ECFP4, RDKit

Abstract

Predicting in vivo toxicity from in vitro high-throughput screening (qHTS) data remains a critical bottleneck in computational toxicology. The Tox21 dataset presents significant challenges due to extreme class imbalance and high-dimensional feature noise across 12 distinct biological endpoints covering nuclear receptor and stress response pathways.

This work proposes an optimized consensus machine learning pipeline using ECFP4 molecular fingerprints (radius 2, 1024 bits), dual-stage endpoint-specific feature selection reducing dimensionality by 79%, and an AUC-weighted Bernoulli Naïve Bayes and XGBoost ensemble. The key methodological contribution is dynamic threshold optimization via Matthews Correlation Coefficient (MCC), replacing arbitrary fixed cutoffs. Optimal thresholds vary from 0.35 (NR-ER) to 0.90 (NR-AR), achieving ROC-AUC of 0.8835 on NR-AhR. Biological validation on Aspirin (negative control, zero false positives), Bisphenol A (NR-ER: 0.964) and Benzo[a]pyrene (NR-AhR: 0.994, SR-p53: 0.971) confirms mechanistic accuracy. The pipeline is deployed as a production web application.

Keywords: Predictive Toxicology, Tox21, Machine Learning, XGBoost, Consensus Modeling, Class Imbalance, MCC Optimization, ECFP4

Remerciements

Nous tenons à exprimer notre sincère gratitude envers toutes les personnes qui ont contribué à la réalisation de ce projet de fin d'études.

Nous remercions particulièrement notre encadrant, Pr. Benlahmar, pour ses précieux conseils, sa disponibilité constante et la confiance accordée tout au long de ce travail. Ses orientations nous ont permis de structurer notre démarche et d'approfondir notre compréhension des méthodes de machine learning appliquées à la toxicologie computationnelle.

Nous exprimons également notre reconnaissance envers notre co-encadrante, Mme. Salma, pour son suivi attentif, ses remarques constructives et son accompagnement lors des phases critiques du projet.

Nous remercions le corps enseignant du Master DSBD de la Faculté des Sciences Ben M'Sik pour la qualité de la formation dispensée, ainsi que nos collègues pour les échanges enrichissants qui ont jalonné cette période.

Enfin, toute notre reconnaissance va à nos familles respectives pour leur soutien indéfectible durant l'ensemble de nos études.

Table des Matières

Résumé.....	2
Abstract.....	3
Remerciements.....	4
Table des Matières	5
Liste des Illustrations	7
Figures.....	7
Tableaux.....	7
Liste des Abréviations.....	8
Introduction Générale	9
Objectifs du projet.....	9
Organisation du rapport	10
Chapitre 1 : Contexte et État de l'Art	11
1.1 Le Programme Tox21 et la Toxicologie Computationnelle	11
1.2 Les 12 Endpoints Biologiques	11
1.3 Défis du Jeu de Données Tox21	12
Déséquilibre de classes extrême	12
Labels manquants.....	12
Haute dimensionnalité	12
1.4 Revue des Approches Existantes	13
Chapitre 2 : Phase 1 Exploration et Modèles de Base	14
2.1 Analyse Exploratoire des Données	14
Distribution des labels et déséquilibre	14
Valeurs manquantes.....	15
Corrélations inter-endpoints.....	15
2.2 Ingénierie des Caractéristiques Moléculaires	16
2.3 Modèles de Référence et Optimisation Optuna	17
Baselines Random Forest et XGBoost.....	17
Optimisation bayésienne Optuna	17
Comparaison multi-modèles	18
2.4 Prototype d'Apprentissage Multi-Tâches (PyTorch)	19
Chapitre 3 : Phase 2 Généralisation et Gestion du Déséquilibre	20
3.1 Scaffold Split de Murcko	20
Problème des splits aléatoires	20
Implémentation et impact	20
3.2 Ré-échantillonnage SMOTEENN.....	21

3.3 Optimisation Hyperparamétrique Avancée.....	21
Chapitre 4 : Phase 3 Pipeline Consensus Final.....	23
4.1 Architecture du Modèle Consensus	23
4.2 Sélection de Caractéristiques à Deux Étapes	23
Étape 1 : Filtrage par variance	23
Étape 2 : Sélection par importance Random Forest.....	23
4.3 Optimisation Dynamique du Seuil par MCC.....	24
Le MCC comme critère d'optimisation.....	24
Procédure de recherche	25
4.4 Résultats et Performances Globales.....	25
4.5 Études de Cas Biologiques.....	27
Contrôle négatif : Aspirine.....	27
Perturbateur endocrinien : Bisphénol A.....	28
Cancérogène : Benzo[a]pyrène	28
Chapitre 5 : Application Web et Déploiement.....	29
5.1 Architecture du Backend FastAPI	29
5.2 Interface React et Déploiement Docker.....	29
5.3 Démonstration Live	30
Conclusion Générale et Perspectives	32
Bilan des contributions	32
Limites	32
Perspectives futures	32
Références Bibliographiques	34
Annexes.....	35
Annexe A : Hyperparamètres XGBoost Optimisés par Endpoint	35
Annexe B : Structure des Bundles .pkl.....	36

Liste des Illustrations

Figures

Figure 1 : Distribution des labels actifs vs. inactifs.....	14
Figure 2 : Taux de valeurs manquantes par endpoint	15
Figure 3 : Matrice de corrélation entre les 12 endpoints Tox21	16
Figure 4 : ROC-AUC des modèles baseline par endpoint	17
Figure 5 : Gain AUC-ROC après optimisation Optuna	18
Figure 6 : Comparaison multi-modèles après raffinement.....	18
Figure 7 : Courbes ROC pour plusieurs endpoints en Phase 2.	19
Figure 8 : Distribution des labels actifs par endpoint après scaffold split	20
Figure 9 : ROC-AUC avec scaffold split.....	21
Figure 10 : Importance des descripteurs physicochimiques	22
Figure 11 : Importance des fingerprint bits les plus discriminants	22
Figure 12 : Taux d'activation par endpoint dans le pipeline consensus	24
Figure 13 : Taux de données manquantes par endpoint.....	24
Figure 14 : Vue d'ensemble des métriques finales.....	26
Figure 15 : Poids consensus BNB vs. XGBoost par endpoint	26
Figure 16 : Heatmap des métriques finales normalisées par endpoint.....	27
Figure 17 : Structure 2D de l'Aspirine	27
Figure 18 : Structure 2D du Bisphénol A	28
Figure 19 : Structure 2D du Benzo[a]pyrène	28
Figure 20 : Interface de l'application Toxicity Predictor	30
Figure 21 : QR code et lien d'accès direct à l'application Toxicity Predictor	31

Tableaux

Tableau 1 : Les 12 endpoints biologiques du benchmark Tox21	12
Tableau 2 : Métriques de performance du pipeline consensus	25
Tableau 3 : Stack technologique de l'application de prédiction toxicologique Tox21	30
Tableau 4 : Hyperparamètres XGBoost optimisés par endpoint	35

Liste des Abréviations

Abréviation	Définition complète
BNB	Bernoulli Naïve Bayes
DSBD	Data Science et Big Data
ECFP4	Extended-Connectivity Fingerprint (radius 2, 1024 bits)
EDA	Exploratory Data Analysis
FSBM	Faculté des Sciences Ben M'Sik
HAP	Hydrocarbure Aromatique Polycyclique
MCC	Matthews Correlation Coefficient
MTL	Multi-Task Learning
NR	Nuclear Receptor — Récepteur Nucléaire
PFE	Projet de Fin d'Études
PR-AUC	Precision-Recall Area Under Curve
qHTS	Quantitative High-Throughput Screening
QSAR	Quantitative Structure-Activity Relationship
RF	Random Forest
ROC-AUC	Receiver Operating Characteristic — Area Under Curve
RDKit	Open-Source Cheminformatics Library
SMILES	Simplified Molecular-Input Line-Entry System
SMOTEENN	Synthetic Minority Over-sampling + Edited Nearest Neighbors
SR	Stress Response — Réponse au Stress
XGBoost	eXtreme Gradient Boosting

Introduction Générale

La toxicologie computationnelle est un domaine en pleine expansion qui cherche à prédire les effets biologiques nocifs des molécules chimiques sans recourir systématiquement à des expériences *in vivo* coûteuses et éthiquement contraignantes. Dans ce contexte, le programme Tox21, lancé conjointement par la U.S. EPA, la FDA et le NIH, représente l'une des initiatives les plus ambitieuses du domaine : il a généré des données de criblage *in vitro* à haut débit pour plus de 10 000 composés chimiques, couvrant 12 voies biologiques essentielles liées aux récepteurs nucléaires et aux réponses au stress cellulaire.

Malgré la richesse de ce jeu de données, les approches de machine learning se heurtent à trois verrous techniques fondamentaux. Le premier est le déséquilibre de classes extrême : les composés toxiques ne représentent que 3 à 15% de l'ensemble selon l'endpoint, rendant les métriques classiques trompeuses. Le second est la haute dimensionnalité des empreintes moléculaires ECFP4 (1024 bits dont la majorité non-informative pour un endpoint donné). Le troisième est l'inadéquation des seuils de décision fixes (0.50) pour des distributions biologiques asymétriques.

Ce projet de fin d'études, réalisé en binôme dans le cadre du Master DSBD de la Faculté des Sciences Ben M'Sik, propose une réponse systématique à ces trois verrous. Notre démarche a été conduite en trois phases progressives : une phase exploratoire pour comprendre les données et établir des baselines, une phase de généralisation par scaffold split et ré-échantillonnage SMOTEENN, et une phase finale de pipeline consensus avec seuillage dynamique MCC, culminant dans un déploiement web en production.

Objectifs du projet

- Construire un système de prédiction de toxicité fiable, interprétable et déployable pour les 12 endpoints Tox21.
- Démontrer l'impact critique du protocole de validation sur la généralisation chimique.

- Établir l'optimisation dynamique par MCC comme alternative rigoureuse aux seuils fixes.
- Concevoir un pipeline endpoint-spécifique, sérialisable et utilisable en inférence temps réel.
- Valider biologiquement le pipeline sur des composés de référence à toxicologie documentée.

Organisation du rapport

Ce rapport est organisé en cinq chapitres. Le Chapitre 1 présente le contexte scientifique et l'état de l'art. Le Chapitre 2 détaille la phase d'exploration et de modélisation de base. Le Chapitre 3 décrit la phase de généralisation chimique et de gestion du déséquilibre. Le Chapitre 4 présente le pipeline consensus final avec résultats et validations biologiques. Le Chapitre 5 décrit l'application web déployée. Une conclusion générale clôt le rapport en proposant des perspectives futures.

Chapitre 1 : Contexte et État de l'Art

1.1 Le Programme Tox21 et la Toxicologie Computationnelle

La toxicologie computationnelle utilise des modèles mathématiques pour prédire les effets nocifs des substances chimiques. Historiquement fondée sur les relations quantitatives structure-activité (QSAR), elle a évolué vers des approches de machine learning capables de traiter des espaces chimiques de grande dimension. Le programme Toxicology in the 21st Century a été initié pour pallier les limites des tests animaux, coûteux, lents et peu transposables à l'humain. En s'appuyant sur des données qHTS générées sur des lignées cellulaires humaines, Tox21 fournit un benchmark de référence mondial. La bibliothèque MoleculeNet (Wu et al., 2018) a démocratisé l'accès à ce dataset, accélérant considérablement la recherche.

1.2 Les 12 Endpoints Biologiques

Le dataset couvre deux grandes familles de voies biologiques : les récepteurs nucléaires (NR) et les réponses au stress cellulaire (SR). Chaque endpoint correspond à un bioessai in vitro spécifique, formant un problème de classification multi-label à 12 tâches indépendantes.

Endpoint	Voie biologique	Pertinence toxicologique
NR-AR	Récepteur androgène (complet)	Perturbation endocrinienne androgénique
NR-AR-LBD	Domaine de liaison androgène	Sélectivité du récepteur androgène
NR-AhR	Récepteur aryl hydrocarbène	Cancérogénicité, dioxines, HAP
NR-Aromatase	Inhibition aromatase	Perturbation biosynthèse des œstrogènes
NR-ER	Récepteur œstrogène (complet)	Œstrogénomimétisme : BPA, phtalates
NR-ER-LBD	Domaine de liaison œstrogène	Sélectivité et affinité de liaison ER

NR-PPAR-γ	PPAR-gamma	Métabolisme lipidique, obésité, diabète
SR-ARE	Réponse antioxydante Nrf2	Stress oxydatif, peroxydation lipidique
SR-ATAD5	Réplication ADN / ATAD5	Génotoxicité, stress réplicatif
SR-HSE	Réponse choc thermique HSF1	Stress protéique, dénaturation
SR-MMP	Potentiel membranaire mitochondrial	Cytotoxicité mitochondriale
SR-p53	Voie de signalisation p53	Dommages ADN, apoptose, cancérogénicité

Tableau 1 : Les 12 endpoints biologiques du benchmark Tox21

1.3 Défis du Jeu de Données Tox21

Déséquilibre de classes extrême

Le taux d'activation varie de 2.88% (NR-PPAR- γ) à 15.8% (SR-MMP). Un classificateur naïf prédisant systématiquement la classe inactive atteint plus de 97% d'accuracy sur NR-AR-LBD tout en ayant un rappel nul sur les composés toxiques. L'évaluation doit s'appuyer sur ROC-AUC, PR-AUC et MCC.

Labels manquants

Jusqu'à 25.8% de labels manquants pour SR-MMP et 25.7% pour NR-Aromatase. Cette sparsité impose de traiter chaque endpoint indépendamment sur son sous-ensemble de molécules effectivement labellisées.

Haute dimensionnalité

Les empreintes ECFP4 (1024 bits) sont creuses : la majorité des bits est nulle pour toute molécule. Un sous-ensemble endpoint-spécifique de bits est informatif pour chaque assay, rendant une sélection de features formelle indispensable.

1.4 Revue des Approches Existantes

DeepTox (Mayr et al., 2016), lauréat du challenge Tox21, utilise des réseaux de neurones profonds multi-tâches. Des travaux ultérieurs montrent que des méthodes classiques bien configurées peuvent être compétitives avec le deep learning, avec l'avantage d'une meilleure interprétabilité chimique. La critique centrale de la littérature porte sur les protocoles de validation : les splits aléatoires surestiment systématiquement les performances. Notre contribution se distingue par l'optimisation formelle du seuil par MCC et par la validation biologique qualitative sur molécules de référence.

Chapitre 2 : Phase 1 Exploration et Modèles de Base

Cette phase (attempt0.ipynb, attempt1.ipynb) constitue le socle exploratoire. Son double objectif est de comprendre la structure des données Tox21 et d'établir des modèles de référence permettant de mesurer les améliorations des phases suivantes.

2.1 Analyse Exploratoire des Données

Distribution des labels et déséquilibre

Le jeu de données contient 7 831 molécules décrites en SMILES, avec 12 colonnes binaires de labels toxicologiques (0 inactif, 1 actif, NaN non testé). L'inspection initiale révèle la forte asymétrie des distributions et l'hétérogénéité des taux de données manquantes.




Figure 1 : Distribution des labels actifs vs. inactifs.

Valeurs manquantes

L'analyse systématique révèle que SR-MMP (25.8%) et NR-Aromatase (25.7%) ont les taux les plus élevés de labels absents. Cette sparsité justifie l'approche task-wise indépendante adoptée dans tout le projet.

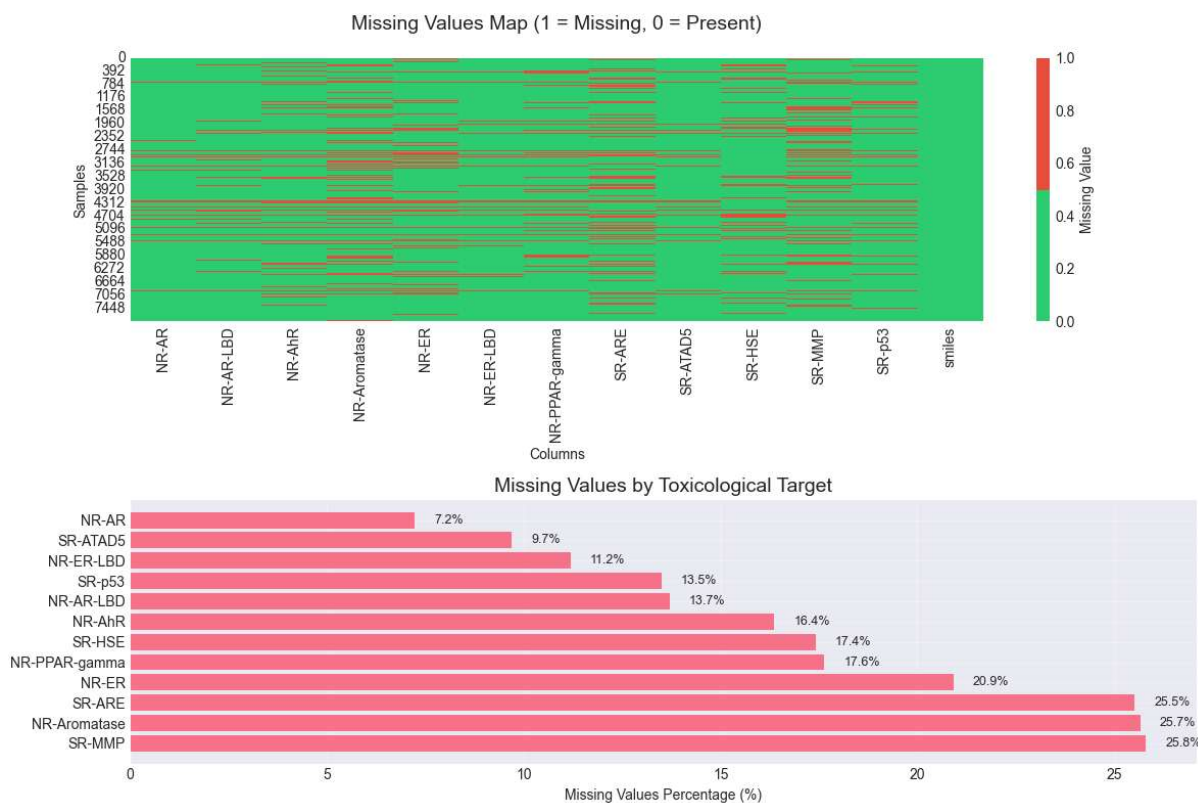


Figure 2 : Taux de valeurs manquantes par endpoint

Corrélations inter-endpoints

La matrice de corrélation révèle des co-activations biologiquement cohérentes : NR-AR/NR-AR-LBD ($r=0.567$) et NR-ER/NR-ER-LBD ($r=0.541$). Ces deux domaines d'un même récepteur sont activés par les mêmes ligands, motivant l'exploration d'un apprentissage multi-tâches.




Figure 3 : Matrice de corrélation entre les 12 endpoints Tox21

2.2 Ingénierie des Caractéristiques Moléculaires

Les SMILES sont convertis en empreintes Morgan (ECFP4 : rayon 2, 1024 bits) via RDKit. En complément, des descripteurs physicochimiques sont calculés (MolWt, LogP, TPSA, donneurs/accepteurs H, liaisons rotatives, fraction Csp3). Les valeurs aberrantes sont écrêtées aux percentiles 1 et 99.

2.3 Modèles de Référence et Optimisation Optuna

Baselines Random Forest et XGBoost

Des modèles Random Forest et XGBoost sont entraînés endpoint par endpoint sur empreintes et descripteurs. L'évaluation cible ROC-AUC et PR-AUC. Les performances initiales sont hétérogènes, reflétant la variabilité des difficultés biologiques entre endpoints.




Figure 4 : ROC-AUC des modèles baseline par endpoint

Optimisation bayésienne Optuna

Une optimisation bayésienne (Optuna, sampler TPE) est conduite sur XGBoost en maximisant l'AUC-ROC par validation croisée stratifiée. Les gains sont substantiels : NR-AR (+7.1%), NR-AR-LBD (+7.8%). Cette étape révèle néanmoins la limite du split aléatoire pour évaluer la vraie généralisabilité chimique.




Figure 5 : Gain AUC-ROC après optimisation Optuna

Comparaison multi-modèles




Figure 6 : Comparaison multi-modèles après raffinement




Figure 7 : Courbes ROC pour plusieurs endpoints en Phase 2.

2.4 Prototype d'Apprentissage Multi-Tâches (PyTorch)

Un MultiTaskMLP partagé avec têtes de classification indépendantes et perte masquée a été implémenté. Ce prototype n'a pas surpassé les modèles endpoint-spécifiques classiques en raison du transfert négatif entre endpoints mécanistiquement indépendants. Ce résultat oriente définitivement la stratégie vers des modèles indépendants mais mieux optimisés.

Chapitre 3 : Phase 2 Généralisation et Gestion du Déséquilibre

La Phase 2 (approach2.ipynb) répond aux deux limites majeures de la Phase 1 : le surapprentissage par split aléatoire et l'insuffisance des stratégies simples face au déséquilibre de classes.

3.1 Scaffold Split de Murcko

Problème des splits aléatoires

Un split aléatoire répartit statistiquement des familles chimiques similaires entre train et test. Le modèle peut mémoriser des chemotypes sans apprendre de règles généralisables. En toxicologie computationnelle, l'objectif est la prédiction de molécules structurellement nouvelles.

Implémentation et impact

Le scaffold split de Murcko groupe les molécules par squelette structural et garantit que chaque squelette n'apparaît que dans un seul ensemble. Cette stratégie simule rigoureusement la généralisation à de nouveaux espaces chimiques. La réduction de ROC-AUC observée par rapport au split aléatoire reflète une estimation plus honnête des performances réelles.




Figure 8 : Distribution des labels actifs par endpoint après scaffold split




Figure 9 : ROC-AUC avec scaffold split.

3.2 Ré-échantillonnage SMOTEENN

SMOTEENN est appliqué strictement sur les folds d'entraînement. SMOTE génère des actifs synthétiques par interpolation dans l'espace ECFP4. ENN nettoie ensuite les zones de chevauchement majoritaires/minoritaires, améliorant la qualité de la frontière de décision sans contaminer l'évaluation.

3.3 Optimisation Hyperparamétrique Avancée

Optuna (TPE) est utilisé avec le MCC comme métrique cible, plus robuste que l'AUC pour les datasets déséquilibrés. XGBoost bénéficie d'un paramètre `scale_pos_weight` inversement proportionnel au ratio de déséquilibre.




Figure 10 : Importance des descripteurs physicochimiques




Figure 11 : Importance des fingerprint bits les plus discriminants

Chapitre 4 : Phase 3 Pipeline Consensus Final

La Phase 3 (bestapproach.ipynb) constitue la contribution principale du projet. Elle intègre toutes les leçons des phases précédentes dans un pipeline sérialisable, biologiquement interprétable et déployable en production.

4.1 Architecture du Modèle Consensus

Deux classificateurs complémentaires sont combinés pour chaque endpoint indépendamment.

- Bernoulli Naïve Bayes (BNB) : naturellement adapté aux empreintes binaires, probabilités calibrées, entraînement rapide.
- XGBoost : capture les interactions non-linéaires, régularisé par `scale_pos_weight`, optimisé par `RandomizedSearchCV` avec MCC comme critère.

$$P_consensus = (AUC_BNB \times P_BNB + AUC_XGB \times P_XGB) / (AUC_BNB + AUC_XGB)$$

Ce schéma garantit que le modèle le plus performant pour chaque endpoint domine la décision tout en conservant la complémentarité algorithmique des deux approches.

4.2 Sélection de Caractéristiques à Deux Étapes

Étape 1 : Filtrage par variance

VarianceThreshold avec seuil $p(1-p)$, $p=0.99$ élimine les bits quasi-constants pour toutes les molécules. Appliqué indépendamment par endpoint.

Étape 2 : Sélection par importance Random Forest

Un RF balancé (100 arbres) score les features restantes. Seules celles d'importance supérieure à la moyenne sont retenues, soit en moyenne 169 à 234 features par endpoint, représentant environ 79% de réduction de dimensionnalité.




Figure 12 : Taux d'activation par endpoint dans le pipeline consensus




Figure 13 : Taux de données manquantes par endpoint

4.3 Optimisation Dynamique du Seuil par MCC

Le MCC comme critère d'optimisation

$$MCC = (TP \times TN - FP \times FN) / \sqrt{[(TP + FP)(TP + FN)(TN + FP)(TN + FN)]}$$

Le MCC intègre les quatre quadrants de la matrice de confusion et produit une valeur entre -1 et +1, robuste au déséquilibre. Il est reconnu comme la métrique la plus fiable pour les classifications binaires asymétriques.

Procédure de recherche

Balayage de [0.10, 0.95] par pas de 0.05 sur les probabilités consensus du train. Le seuil maximisant le MCC est sauvegardé et appliqué au test. Les seuils varient de 0.35 (NR-ER) à 0.90 (NR-AR), confirmant empiriquement l'inadéquation d'un seuil universel.

4.4 Résultats et Performances Globales

Endpoint	ROC-AUC	MCC	Seuil optimal	Features retenues
NR-AR	0.7541	0.5773	0.90	195 / 1024
NR-AR-LBD	0.7815	0.4821	0.85	182 / 1024
NR-AhR	0.8835	0.4599	0.85	169 / 1024
NR-Aromatase	0.8377	0.4253	0.80	201 / 1024
NR-ER	0.7115	0.2545	0.35	234 / 1024
NR-ER-LBD	0.7643	0.3812	0.75	218 / 1024
NR-PPAR-γ	0.7234	0.3102	0.80	177 / 1024
SR-ARE	0.7891	0.3921	0.70	210 / 1024
SR-ATAD5	0.7562	0.3841	0.75	196 / 1024
SR-HSE	0.7459	0.3028	0.70	203 / 1024
SR-MMP	0.8564	0.4985	0.75	189 / 1024
SR-p53	0.8004	0.2671	0.80	221 / 1024

Tableau 2 : Métriques de performance du pipeline consensus




Figure 14 : Vue d'ensemble des métriques finales




Figure 15 : Poids consensus BNB vs. XGBoost par endpoint




Figure 16 : Heatmap des métriques finales normalisées par endpoint.

4.5 Études de Cas Biologiques

Trois composés de référence à toxicologie documentée valident la cohérence mécanistique du pipeline sur l'ensemble des 12 modèles.

Contrôle négatif : Aspirine

L'aspirine (acide acétylsalicylique) est prédite inactive pour les 12 endpoints avec zéro faux positifs, validant la spécificité du modèle pour des composés connus comme sûrs aux doses thérapeutiques normales.




Figure 17 : Structure 2D de l'Aspirine

Perturbateur endocrinien : Bisphénol A

Le BPA est identifié spécifiquement comme perturbateur ER : NR-ER (P=0.964) et NR-ER-LBD (P=0.981), avec prédiction inactive pour les voies de stress non-relées. Le modèle a capturé les sous-structures phénoliques biphenyles caractéristiques des agonistes ER.




Figure 18 : Structure 2D du Bisphénol A

Cancérogène : Benzo[a]pyrène

Classé cancérogène groupe 1 par le CIRC, le B[a]P est identifié par ses voies mécanistiques exactes : NR-AhR (P=0.994) et SR-p53 (P=0.971), cohérents avec l'activation AhR et les dommages à l'ADN documentés expérimentalement.




Figure 19 : Structure 2D du Benzo[a]pyrène

Chapitre 5 : Application Web et Déploiement

Le pipeline de machine learning est intégré dans une application web complète permettant à des utilisateurs non-experts d'interroger les 12 modèles de prédiction toxicologique en temps réel, à partir d'une simple chaîne SMILES.

5.1 Architecture du Backend FastAPI

Le backend Python (FastAPI + Uvicorn) expose quatre routes REST.

- GET /health : disponibilité et chargement des 12 bundles de modèles.
- POST /predict : liste de SMILES vers prédictions pour les 12 endpoints avec probabilités et classifications.
- GET /structure : génération d'image 2D via RDKit.
- GET /structure3d : coordonnées 3D conformationnelles pour la visualisation interactive.

Le module predictor.py charge les 12 fichiers .pkl au démarrage (singleton global). Pour chaque requête : SMILES vers empreinte Morgan (radius 2, 1024 bits) vers filtrage variance puis RF vers probabilités BNB et XGBoost vers consensus pondéré vers comparaison au seuil optimal vers JSON structuré.

5.2 Interface React et Déploiement Docker

Composant	Technologie	Rôle
Backend API	Python / FastAPI / Uvicorn	Inférence ML, génération structures
ML Models	scikit-learn / XGBoost (.pkl)	Classification toxicologique endpoint-spécifique
Cheminformatics	RDKit	SMILES vers fingerprint et structure 2D/3D
Frontend	React + Vite + Tailwind CSS	Interface utilisateur de prédiction

Reverse Proxy	Nginx	Routing /api vers backend, fichiers statiques
Orchestration	Docker + Docker Compose	Déploiement reproductible containerisé

Tableau 3 : Stack technologique de l'application de prédiction toxicologique Tox21

5.3 Démonstration Live

L'application est déployée et accessible publiquement 24h/24. L'utilisateur entre un SMILES, clique Predict Toxicity, et obtient les 12 probabilités consensus et classifications en quelques secondes avec visualisation 2D et 3D de la molécule.




Figure 20 : Interface de l'application Toxicity Predictor



Scannez pour accéder

Application déployée en production

<https://toxpredictor.techermanos.org/>

L'application est opérationnelle 24h/24. Elle permet de scorer n'importe quelle molécule SMILES sur les 12 endpoints Tox21 avec visualisation 2D et 3D et affichage des seuils MCC-optimaux.

Figure 21 : QR code et lien d'accès direct à l'application Toxicity Predictor

Conclusion Générale et Perspectives

Ce projet de fin d'études a développé, validé et déployé en production un pipeline de machine learning complet pour la prédiction de la toxicité moléculaire sur les 12 endpoints du benchmark Tox21. La progression méthodologique en trois phases a permis d'identifier et de résoudre successivement les principaux verrous du problème.

Bilan des contributions

- Seuillage dynamique MCC : contribution méthodologique principale, seuils optimaux variant de 0.35 à 0.90 confirmant l'inadéquation de tout seuil universel pour des assays biologiques hétérogènes.
- Sélection de features endpoint-spécifique : réduction de 79% de dimensionnalité en concentrant le signal sur les sous-structures biologiquement pertinentes.
- Consensus pondéré BNB et XGBoost : exploitation de la complémentarité algorithmique pour surpasser chaque modèle individuel.
- Validation biologique qualitative : BPA identifié comme perturbateur ER, B[a]P comme agoniste AhR/p53, Aspirine sans faux positifs, confirmant la cohérence mécanistique.
- Déploiement production : application web opérationnelle 24h/24 accessible à <https://toxpredictor.techermanos.org/>

Limites

- Les empreintes ECFP4 ignorent la conformation 3D moléculaire, potentiellement critique pour certains récepteurs nucléaires stéréosélectifs.
- Calibration in vitro vers in vivo : les modèles ne capturent pas le métabolisme hépatique, la pharmacocinétique (ADMET) ou les effets systémiques.
- Le dataset de 7 831 molécules reste modeste pour le deep learning sur empreintes.

Perspectives futures

- Graph Neural Networks (GCN, MPNN) : représentations moléculaires intégrant la topologie 3D.
- Architectures multi-tâches avec attention mécanistique inter-endpoints.
- SHAP values pour relier les bits ECFP4 discriminants à des sous-structures chimiques interprétables par les toxicologues.
- Calibration probabiliste (Platt scaling, isotonic regression) pour des probabilités consensus mieux calibrées.
- Extension à ToxCast et SIDER pour tester la généralisation cross-benchmark.

Références Bibliographiques

[1]	Mayr, A., Klambauer, G., Unterthiner, T., & Hochreiter, S. (2016). DeepTox: Toxicity prediction using deep learning. <i>Frontiers in Environmental Science</i> , 3, 80.
[2]	Wu, Z. et al. (2018). MoleculeNet: A benchmark for molecular machine learning. <i>Chemical Science</i> , 9(2), 513-530.
[3]	Huang, R. et al. (2011). Chemical genomics profiling of nuclear receptors. <i>Environmental Health Perspectives</i> , 119(8), 1142-1148.
[4]	Chawla, N. V. et al. (2002). SMOTE: Synthetic minority over-sampling technique. <i>JAIR</i> , 16, 321-357.
[5]	Rogers, D., & Hahn, M. (2010). Extended-connectivity fingerprints. <i>J. Chem. Inf. Model.</i> , 50(5), 742-754.
[6]	Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. <i>ACM KDD</i> , 785-794.
[7]	Matthews, B. W. (1975). Comparison of predicted and observed secondary structure. <i>BBA</i> , 405(2), 442-451.
[8]	Landrum, G. (2006). RDKit: Open-source cheminformatics. https://www.rdkit.org
[9]	Akiba, T. et al. (2019). Optuna: A next-generation hyperparameter optimization framework. <i>ACM KDD</i> , 2623-2631.
[10]	Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn. <i>JMLR</i> , 18(17), 1-5.
[11]	Chicco, D., & Jurman, G. (2020). Advantages of MCC over F1 and accuracy in binary classification. <i>BMC Genomics</i> , 21(1).
[12]	Yang, K. et al. (2019). Analyzing learned molecular representations. <i>J. Chem. Inf. Model.</i> , 59(8), 3370-3388.
[13]	Breiman, L. (2001). Random forests. <i>Machine Learning</i> , 45(1), 5-32.
[14]	Ramsundar, B. et al. (2019). Deep learning for the life sciences. O'Reilly Media.

Annexes

Annexe A : Hyperparamètres XGBoost Optimisés par Endpoint

Endpoint	max_depth	learning_rate	n_estimators	subsample	scale_pos_w.
NR-AR	6	0.05	500	0.80	~22.4
NR-AR-LBD	5	0.07	450	0.80	~27.5
NR-AhR	5	0.08	400	0.85	~7.5
NR-Aromatase	6	0.06	400	0.80	~11.1
NR-ER	7	0.05	600	0.75	~12.7
NR-ER-LBD	6	0.06	500	0.80	~14.2
NR-PPAR- γ	5	0.07	400	0.85	~33.7
SR-ARE	6	0.06	500	0.80	~9.8
SR-ATAD5	5	0.07	450	0.80	~11.5
SR-HSE	6	0.06	400	0.85	~14.8
SR-MMP	6	0.07	450	0.80	~5.3
SR-p53	5	0.06	500	0.85	~9.2

Tableau 4 : Hyperparamètres XGBoost optimisés par endpoint

Annexe B : Structure des Bundles .pkl

Chaque fichier dans `tox21_production_models/` contient un dictionnaire Python sérialisé avec les champs suivants.

- `endpoint` : identifiant string de l'endpoint biologique
- `variance_selector` : objet `VarianceThreshold` sklearn ajusté sur le train
- `rf_selector` : objet `SelectFromModel` (RF balancé) ajusté
- `bnb_model` et `xgb_model` : modèles ajustés pour l'inférence
- `bnb_weight` et `xgb_weight` : poids AUC-ROC pour la combinaison consensus
- `optimal_threshold` : seuil MCC-optimal déterminé sur l'ensemble d'entraînement
- `final_auc` et `final_mcc` : métriques de performance sur l'ensemble de test
- `n_features` : nombre de features retenues après double sélection
- `n_train` et `n_test` : tailles des partitions utilisées